



Projet programmation en python

Réalisé par : MAHAMOUD ISMAN Abdoulrazack

A l'intention de : Julien Velcin

Sommaire :

Introduction	3
I. Description de l'environnement de travail et données	3
1. Environnement de travail et répartition de tâche	3
2. Diagramme de classe	3
II. Conception du programme	4
1. Algorithmes spécifiques	4
2. Problème rencontré	5
3. Exemple d'utilisation de l'application.....	6-8
III. Maintenance	9

Lien github du projet : https://github.com/mahamoud2020/projet_pyton_reddit-arxiv

Introduction

Dans le cadre du cours de « programmation de spécialité python », nous sommes amenés à réaliser un projet qui consiste à faire une analyse comparative entre deux corpus : Reddit et Arxiv. L'objectif principal de ce projet est d'observer l'importance d'un mot ou plusieurs mots dans un corpus à l'autre.

Reddit est un site web communautaire américain d'actualités sociales mais aussi d'un forum où le contenu est classé par sous catégorie et est accessible aux utilisateurs.

Arxiv, quand à lui, est une bibliothèque scientifique contenant plus d'un millions de publications. En accès libre, Arxiv aborde de diverses thématiques dans différents domaines comme l'informatique ou le mathématique.

I. Description de l'environnement de travail et données

1. Environnement de travail et répartition de tâche

N'ayant pas trouvé un binôme avec qui j'aurais la possibilité de travailler ensemble, j'ai réalisé ce projet en solo.

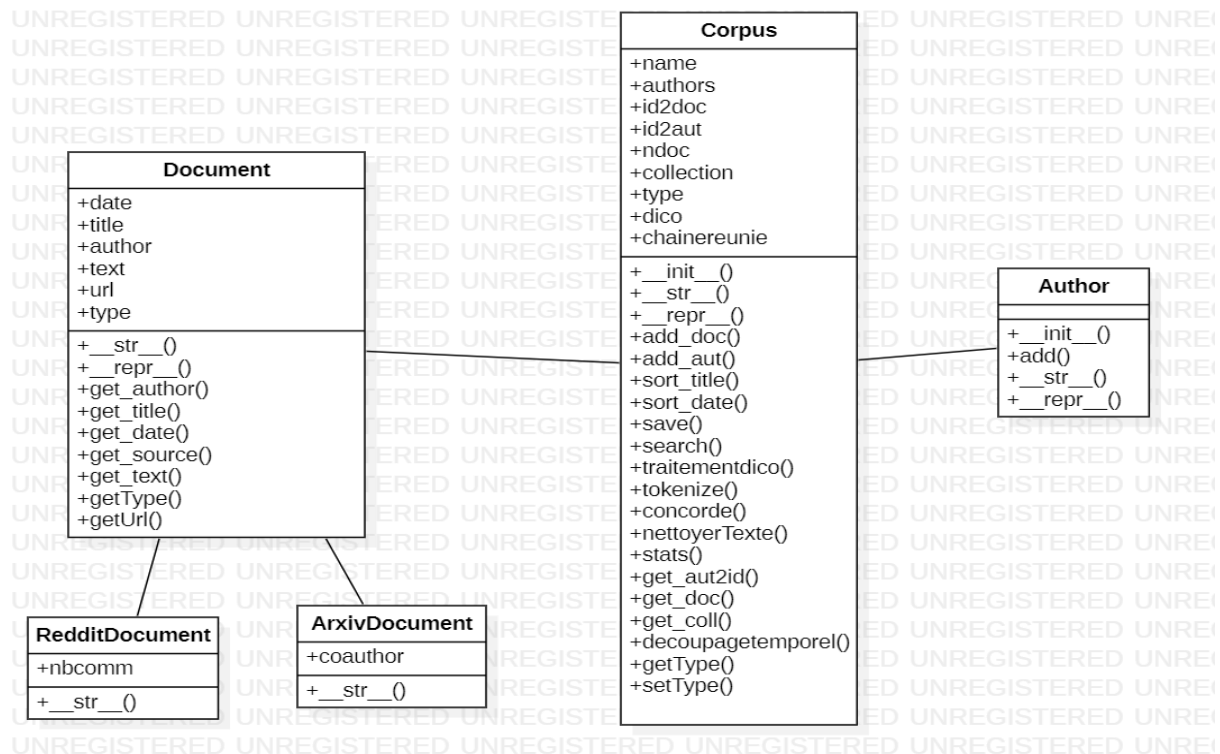
Pour ce qui est environnement de travail, comme on est habitué à travaillé sur spyder en TD, j'ai gardé ce même environnement.

Concernant la réalisation de l'interface visuelle, j'avais le choix entre Dash et Tkinter. J'ai opté pour Tkinter qui est un module intégré à Python pour développer des applications graphiques.

2. Diagramme de classe

Le programme repose sur deux classes principales : Document et Corpus. La classe Document est la mère de deux autres classes qui héritent toutes ces propriétés. Il s'agit de la classe RedditDocument et ArxivDocument.

Le diagramme de classe ci-dessous détaille les attributs et les méthodes utilisées dans ce programme.



Ce diagramme de classe est réalisé sous le logiciel starUML. Je rajouterai une version originale téléchargée directement depuis le logiciel.

II. Conception du programme

Dans cette partie je vais décortiquer les différents algorithmes utilisés dans la conception du programme.

1. Algorithmes spécifiques

Plusieurs algorithmes sont utilisés pendant les différentes étapes de la conception de l'application. Etant données que les données provenant de ces deux corpus ne sont exploitable, la première étape à faire est de nettoyer les données afin de les rendre exploitables et les utiliser dans les algorithmes. Pour cela, je réunie les informations des documents du corpus dans une seule chaine de caractère pour effectuer par la suite le processus de nettoyage. La librairie « nltk » fournit des diverses méthodes utiles pour le nettoyage de données comme : « stopwords », « RegexpToxerizer », et « word_tokenizer. Stopwords ».

Par le biais de toutes ces méthodes, j'ai effectué ces traitements :

- Suppression de toutes les expressions entre crochets, accolades, parenthèses.
- Suppression de la ponctuation et de certains caractères spéciaux.
- Suppression des chiffres.
- Conversion en minuscule du texte de chaque document.
- Suppression de stopwords (mots n'ayant pas de sens dans la compréhension du texte).

Parmi les algorithmes utilisés dans ce programme, il y a aussi la librairie scikit-learn qui nous propose des multiples fonctions comme « CountVectorizer » et « TfidfTransformer » pour faire du calcul de coefficient TF-IDF.

Le fonctionnement de cet algorithme est simple, il faut juste instancier l'objet CountVectorizer() qui va permettre de compter les mots dans le dico, il faut par la suite transformer cette information en coefficient TF-IDF.

Pour la dernière étape, il faut trier les informations dans un dataframe Pandas pour en afficher les plus intéressants et les moins intéressants.

Pour effectuer une analyse comparative de deux corpus, ces deux méthodes sont appelées avec les deux corpus.

L'autre algorithme utilisé est celui qui permet l'évolution temporelle d'un mot ou de plusieurs mots. Le but de cet algo est d'observer le nombre d'occurrences d'un certain terme au cours d'une certaine période, et de tracer une courbe à l'aide la librairie matplotlib.

Pour faire fonctionner cet algo, je commence par récupérer la date d'aujourd'hui et générer un tableau de périodes avec les données entrées par l'utilisateur. Puis je crée un tableau contenant un certain nombre de dates, la taille du tableau étant aussi définie dans un formulaire (exemple: on observe 10 périodes de 3 jours). Enfin je fais le tri chaque document selon ses périodes, et j'ajoute un compteur du terme demandé pour créer un tableau associatif, constituant une clé qui est une date et sa valeur qui est le nombre d'occurrences du terme demandé.

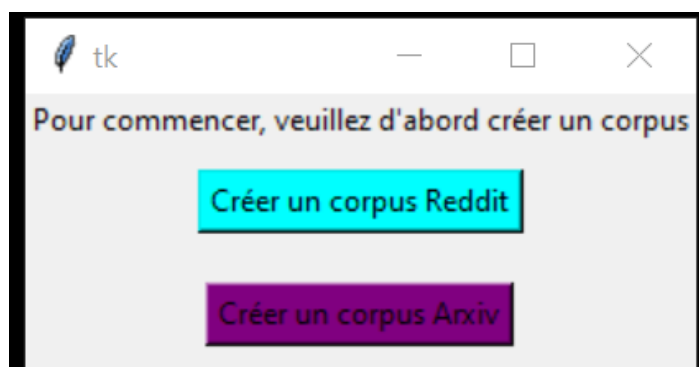
2. Problème rencontré

Le problème majeur rencontré vient du moment de nettoyage des données, c'est-à-dire, la tâche étant de supprimer les mots qui apparaissent une seule fois ou dans un seul document mais il se trouve que parmi ces mots, certains étaient au centre du thème étudié.

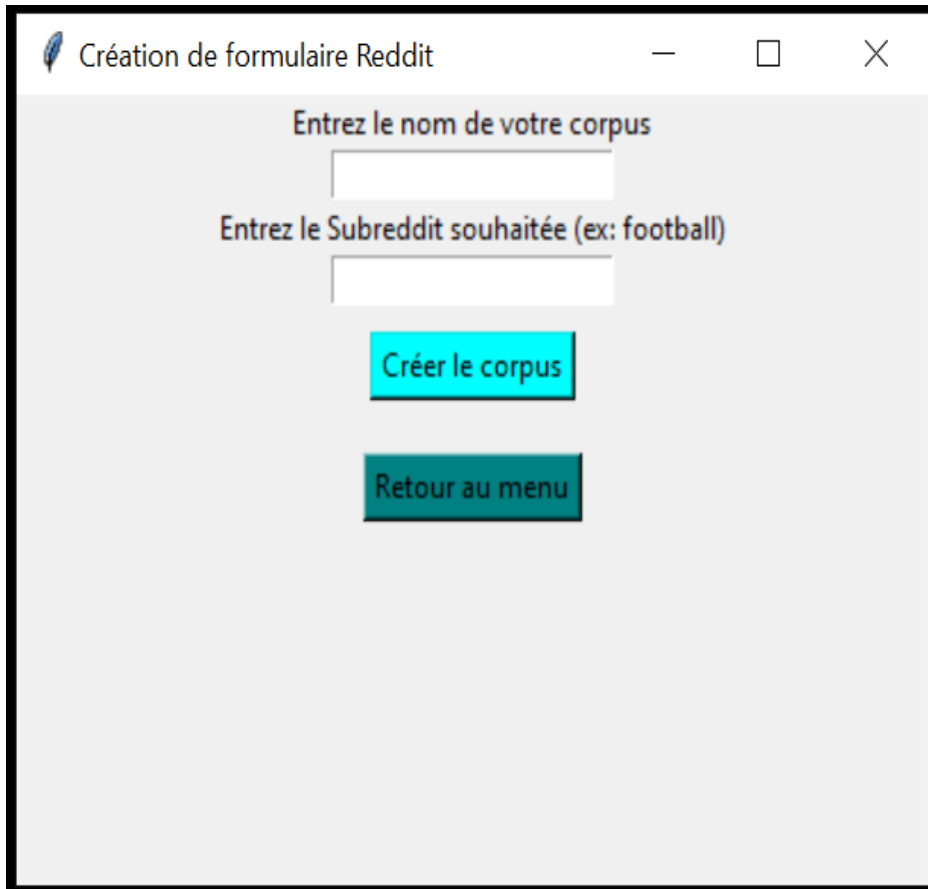
3. Exemple d'utilisation de l'application

Le fonctionnement de l'application se présente ainsi :

Dès le lancement du programme, une fenêtre s'ouvre et demande de saisir quel est le corpus que l'on souhaite créer.



Une fois crée le corpus souhaité, par exemple corpus Reddit. Une autre fenêtre s'ouvre qui va permettre à l'utilisateur de saisir le nom du corpus et la subreddit souhaité (football par ex).



The image shows a web browser window with the title "Création de formulaire Reddit". The window contains a form with two text input fields and two buttons. The first input field is labeled "Entrez le nom de votre corpus" and the second is labeled "Entrez le Subreddit souhaitée (ex: football)". Below the input fields are two buttons: "Créer le corpus" (highlighted in red) and "Retour au menu" (highlighted in blue).

Création de formulaire Reddit

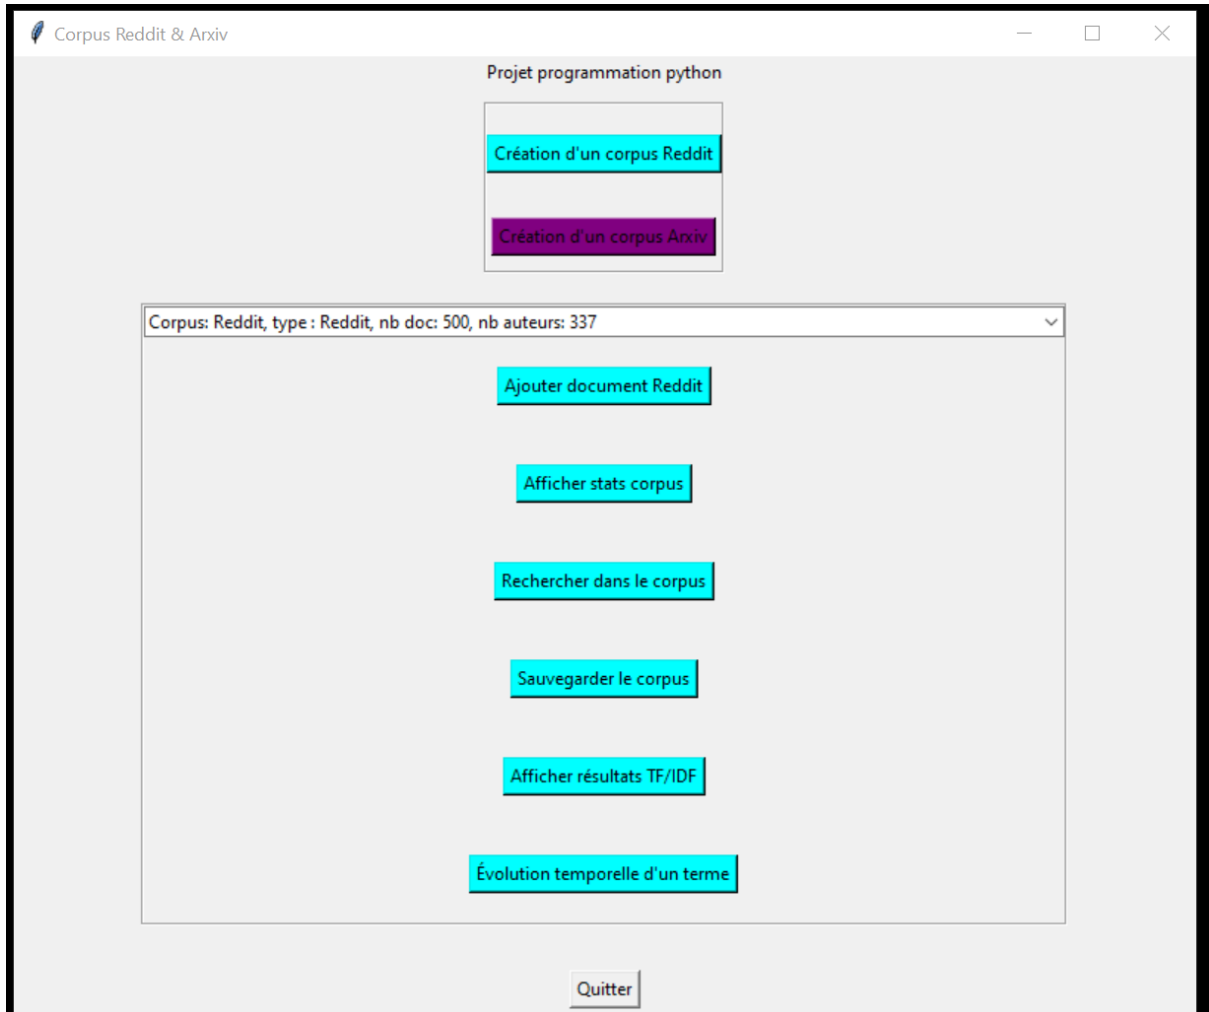
Entrez le nom de votre corpus

Entrez le Subreddit souhaitée (ex: football)

Créer le corpus

Retour au menu

Une fois saisie le nom du corpus et a subreddit et cliquer sur le bouton « créer le corpus », la fenêtre principale s'ouvre où beaucoup de fonctionnalités sont proposées comme : ajouter document Reddit, afficher stats corpus, rechercher dans le corpus, sauvegarder le corpus, etc.

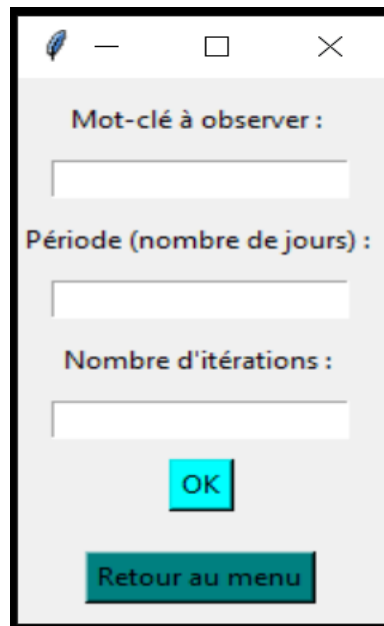


Par exemple avec la fonctionnalité « afficher stats corpus », je peux afficher sur le terminal de spyder le terme le plus utilisé :

Les dix termes les plus utilisés sont :

```
3          209
substitution 181
0          176
football    169
1          166
4          164
2          159
shots       157
match       145
yellow      132
Name: 0, dtype: int64
```

Parmi les fonctionnalités présentes dans l'application, il y a celle qui permet de suivre l'évolution temporelle d'un terme :

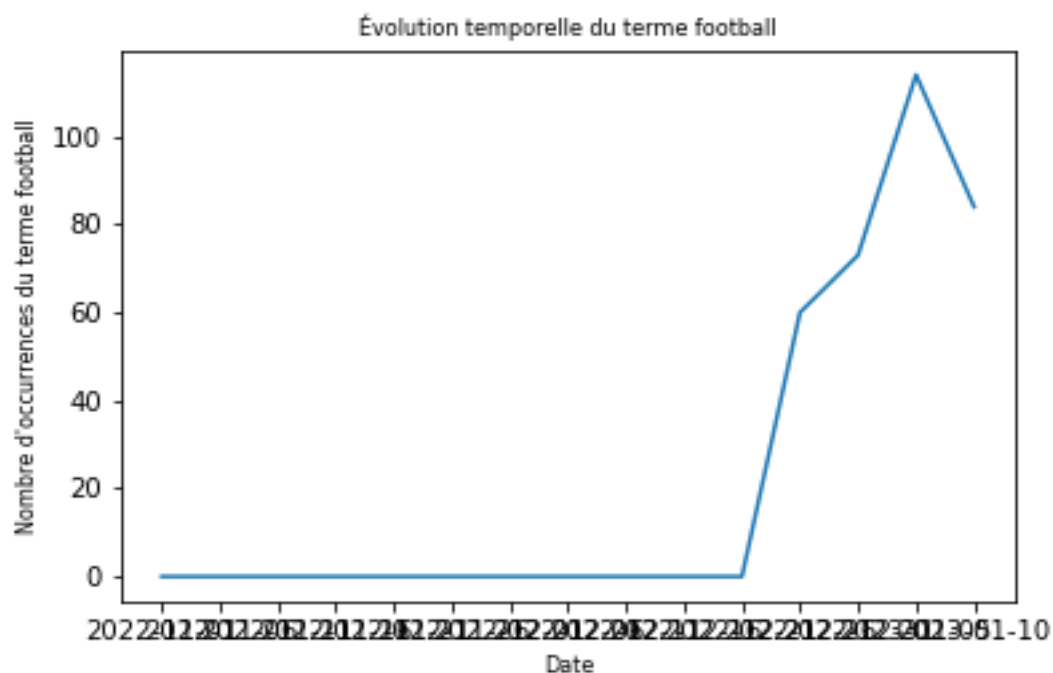


The screenshot shows a web application window with a title bar containing a feather icon, a minus sign, a square icon, and a close button. The main content area has a light gray background and contains three input fields with labels in French: 'Mot-clé à observer :', 'Période (nombre de jours) :', and 'Nombre d'itérations :'. Below these fields are two buttons: a red 'OK' button and a green 'Retour au menu' button.

Dans cette fenêtre, il est possible de suivre un mot souhaité, saisir la période à laquelle on veut suivre et le nombre d'itération choisi.

Le résultat de ces saisies peut être visualisé par une courbe tracée sous Matplotlib.

Voyons à titre d'exemple le résultat d'un terme : « football », période : 5 jours et nombre d'itération 15 :



III. Maintenance

Bien que plusieurs algorithmes soient bien implémentés, ce programme présente quelques failles surtout pour la gestion du problème de crash que les documents ArXiv renvoient.

Sur le plan de l'organisation, je peux avouer que j'aurais réalisé ce projet en binôme non seulement pour partager les tâches mais aussi pour m'entraîner à travailler en équipe car c'est avec ce type de projet académique qu'on apprend à travailler en équipe puis qu'en stage on sera amené à travailler en équipe dans une entreprise .